




**M2.L4: Série d'exercices sur la compression de données [Solutions]****1 Filtre Passe-Bande**

1. Il s'agit de la composée d'un filtre passe bas de fréquence  $f_{ch}$  et d'un passe haut de fréquence  $f_{cb}$
2. Comment conserver seulement les 2 basses fréquences ? Utiliser un passe bas de fréquence 5 Hz



3. Comment conserver seulement les 2 hautes fréquences ? Utiliser un passe haut de fréquence 0.5 Hz





4. Comment conserver seulement la fréquence intermédiaire ? Utiliser un passe bande 0.5 Hz - 5 Hz

## 2 Algorithme de Shannon-Fano

a) En utilisant le jeu des questions, voici le code qu'on trouve:

lettre	nb apparitions	nb questions	mot de code
I	4	3	111
N	4	3	110
O	4	3	101
C	4	3	100
M	3	3	011
A	3	4	0101
T	3	4	0100
L	2	4	0011
U	2	4	0010
F	1	4	0001
R	1	5	00001
E	1	5	00000

- b) Au total, on a donc besoin de  $19 \times 3 + 11 \times 4 + 2 \times 5 = 111$  bits, i.e.  $L(C) = \frac{111}{32} = 3.468975$  bits par lettre.
- c) L'entropie de la séquence est égale à  $H(X) = 3.42923$ . On vérifie donc bien que  $H(X) \leq L(C) \leq H(X) + 1$ , on voit en fait que  $L(C)$  est beaucoup plus proche de  $H(X)$  que de  $H(X) + 1$ .
- d) La séquence contient 12 lettres différentes: si on veut utiliser le même nombre de bits par lettre, on a donc besoin de 4 bits par lettre au minimum (car  $2^4 = 16$ , qui est la puissance de 2 la plus proche au-dessus de 12), et donc de  $32 \times 4 = 128$  bits au total. On utilise donc 17 bits de plus qu'avec le code de Shannon-Fano.
- e) La séquence commençant par DIDON... a un très grand nombre de  $D$  (11 pour être plus précis): on s'attend donc à une plus faible entropie.
- f) En utilisant à nouveau le jeu des questions, voici le code qu'on trouve:

lettre	nb apparitions	nb questions	mot de code
D	11	2	11
N	6	2	10
O	5	3	011
I	4	3	010
U	3	3	001
A	1	4	0001
T	1	5	00001
S	1	5	00000

- f) Le nombre total de bits utilisés est cette fois-ci de  $17 \times 2 + 12 \times 3 + 1 \times 4 + 2 \times 5 = 84$  bits, i.e.  $L(C) = \frac{84}{32} = 2.625$  bits par lettre. Quand à l'entropie de la séquence, elle est égale à  $H(X) = 2.56475$ . A nouveau, on vérifie bien que  $H(X) \leq L(C) \leq H(X) + 1$ , et que  $L(C)$  est plus proche de  $H(X)$  que de  $H(X) + 1$ , même si les probabilités des lettres sont assez irrégulières dans le cas présent.
- g) La séquence contient 8 lettres différentes: si on veut utiliser le même nombre de bits par lettre, on a donc besoin de 3 bits par lettre au minimum (car  $2^3 = 8$ ) et donc de  $32 \times 3 = 96$  bits au total. On utilise donc 12 bits de plus qu'avec le code de Shannon-Fano.

### 3 Codage par plages (run-length encoding)

- a) Vu que chaque ligne de la première image est unicolore, son code RLE est donné par

1111|1111|0111|0111|1111|1111|0111|0111 (longueur totale de 32 bits)

Sur chaque ligne de la deuxième image, on voit le même motif de 4 pixels noirs (encodés par 1011) suivis de 4 pixels blancs (encodés par 0011), donc le code RLE de l'image est

1011|0011|1011|0011|... (longueur totale de 64 bits)

Sur la troisième image, les deux premières lignes sont des séries alternées de noir et blanc, donc avec le codage RLE, chacun des pixels est représenté par 4 bits! (0000 si le pixel est blanc, ou 1000 si le pixel est noir). Donc rien que l'encodage des deux premières lignes requiert  $16 \times 4 = 64$  bits ! (On néglige ici les deux pixels blancs qui se suivent de la fin de la première ligne au début de la seconde). Les six prochaines lignes ne requièrent chacune que 4 bits, comme sur la première image. Au total, on a donc besoin de  $64 + 24 = 88$  bits; clairement pas une compression!

- b) Dans cet exercice, on a choisi d'encoder l'image ligne par ligne, mais rien ne nous empêche de faire la même chose colonne par colonne. Pour préciser notre choix dans le code RLE, il suffit d'ajouter un bit au début: 0 pour "ligne par ligne" et 1 pour "colonne par colonne". On peut ainsi représenter la deuxième image avec 33 bits au total:

1|1111|1111|1111|1111|0111|0111|0111|0111

- c) On voit bien que le codage RLE des deux premières lignes est loin d'être optimal. Une façon de remédier à ça est de changer la structure des paquets, en ajoutant un bit au début de chaque paquet (dont la longueur passe donc à 5 bits): si ce bit vaut 0, alors les quatre prochains bits sont à interpréter au sens du code RLE ci-dessus; par contre, si le premier bit du paquet vaut 1, alors les quatre prochains bits sont simplement les couleurs des 4 pixels de l'image. Ainsi, la troisième image sera encodée par la séquence de bits suivante:

11010|11010|10101|10101|00111|00111|01111|01111|00111|00111

pour une longueur totale de 50 bits (51 si on ajoute le premier bit 0 de la partie b) pour dire qu'on procède ligne par ligne).




Figure 1: à gauche: code de Shannon-Fano; à droite: code de Huffman

## 4 Algorithme de Huffman

L'arbre binaire pour les deux différents codes apparaît sur la figure ci-dessus. Le dictionnaire obtenu par le code de Shannon-Fano est:

$$a \rightarrow 00, b \rightarrow 01, c \rightarrow 10, d \rightarrow 110, e \rightarrow 111$$

Donc le nombre moyen de bits utilisé par le code de Shannon-Fano est:

$$\frac{(39 + 17 + 16) \times 2 + (15 + 13) \times 3}{100} = \frac{228}{100} = 2.28 \text{ bits/lettre}$$

Le dictionnaire obtenu par le code de Huffman est:

$$a \rightarrow 0, b \rightarrow 100, c \rightarrow 101, d \rightarrow 110, e \rightarrow 111$$

Donc le nombre moyen de bits utilisé par le code de Huffman est:

$$\frac{39 \times 1 + (17 + 16 + 15 + 13) \times 3}{100} = \frac{222}{100} = 2.22 \text{ bits/lettre}$$

La limite théorique donnée par le théorème de Shannon est l'entropie:

$$\text{Entropie} = -0.39\log_2(0.39) - 0.17\log_2(0.17) - 0.16\log_2(0.16) - 0.15\log_2(0.15) - 0.13\log_2(0.13) \approx 2.18 \text{ bits/lettre}$$

A noter que dans ce cas, la borne inférieure ne peut pas être atteinte. Du fait que les codes de Huffman sont optimaux (pour la compression sans pertes), on ne peut donc pas trouver dans ce cas un schéma de compression qui fasse mieux que 2.22 bits/lettre. Le théorème de Shannon est vrai pour *tous* les codes et *toutes* les sources. Dans certains cas, la borne inférieure que constitue l'entropie ne peut être atteinte (de fait, le théorème ne dit pas qu'elle doit l'être).